

# **PRACTICA FINAL MÓDULO 03**

## **GIT Y GITHUB**

### **Pregunta 3 : Pull Request.**

**Juan Domingo Ortín**

```
#####  
# 14 Deployment del modelo  
# ¿Cómo se hace el deployment de un modelo de Machine Learning?  
#####  
# 15 (Implemente el modelo en una aplicación web o API)  
# ¿Cómo se implementa un modelo de machine learning en una aplicación web o API?  
# (Esta parte depende de la plataforma de deployment que se elija)  
#####  
#16 Conclusiones  
# (Explique los resultados del proyecto y su impacto en el problema de negocio)  
# Investigar cómo presentar resultados de proyecto de Ciencia de datos que  
impacte al publico
```

#####

## # 14 Deployment del modelo

# ¿Cómo se hace el deployment de un modelo de Machine Learning?

# (Guarda el modelo entrenado para su uso futuro)

Para desplegar un modelo de Machine Learning, se siguen estos pasos de manera detallada:

- 1 **PREPROCESAMIENTO DE DATOS:** Asegúrate de que los datos de entrada estén limpios y formateados correctamente para el modelo:
  - 1.1 **Limpieza de datos:** Elimina datos duplicados, incompletos o incorrectos que puedan afectar negativamente al rendimiento del modelo. Por ejemplo, en un conjunto de datos de ventas minoristas, podrías eliminar filas con valores nulos en las columnas de cantidad vendida o precio.
  - 1.2 **Normalización o estandarización:** Ajusta las características numéricas para que tengan una escala similar, lo que facilita el entrenamiento del modelo. Por ejemplo, en un conjunto de datos de imágenes, puedes normalizar los valores de píxeles para que estén en el rango [0, 1] dividiendo cada valor de píxel por 255.
  - 1.3 **Codificación de variables categóricas:** Convierte las variables categóricas en un formato numérico adecuado para su procesamiento por parte del modelo. Por ejemplo, en un conjunto de datos de encuestas, puedes codificar las respuestas "sí" y "no" como 1 y 0, respectivamente.
  - 1.4 **Selección de características:** Selecciona las características más relevantes y significativas para el modelo, lo que puede mejorar la eficiencia computacional y evitar el sobreajuste. Por ejemplo, en un conjunto de datos de predicción de precios de viviendas, puedes seleccionar solo las características más importantes, como el área de la vivienda y el número de habitaciones.
  - 1.5 **Transformación de datos:** Aplica transformaciones matemáticas o estadísticas a los datos para que cumplan con los supuestos del modelo. Por ejemplo, en un conjunto de datos de distribución de ingresos, puedes aplicar una transformación logarítmica a la variable de ingresos para que se ajuste mejor a una distribución normal.
- 2 **ENTRENAMIENTO DEL MODELO:** Utiliza los datos de entrenamiento para entrenar el modelo de Machine Learning y ajustar sus parámetros:
  - 2.1 **Selección del algoritmo de aprendizaje:** Se elige el algoritmo de Machine Learning más adecuado según el tipo de problema y los datos disponibles, como regresión lineal para problemas de predicción numérica o árboles de decisión para clasificación.
  - 2.2 **División de los datos:** Se dividen los datos de entrenamiento en subconjuntos de entrenamiento y validación para evaluar el rendimiento del modelo durante el entrenamiento y ajustar los hiperparámetros.
  - 2.3 **Entrenamiento del modelo:** Se utilizan los datos de entrenamiento para ajustar los parámetros del modelo y optimizar su capacidad para realizar predicciones precisas sobre nuevos datos. Esto implica ajustar los pesos en una red neuronal, las pendientes en una regresión lineal, o los umbrales en un clasificador de árbol de decisiones.
  - 2.4 **Validación cruzada:** Se utiliza la validación cruzada para evaluar el rendimiento del modelo en múltiples subconjuntos de datos y asegurarse de que no esté sobreajustado.

- 2.5 **Ajuste de hiperparámetros:** Se realizan ajustes en los hiperparámetros del modelo, como la tasa de aprendizaje en redes neuronales o la profundidad máxima en árboles de decisión, para mejorar su capacidad predictiva y generalización.
- 3 **VALIDACIÓN DEL MODELO:** Evalúa el rendimiento del modelo utilizando datos de validación para garantizar su precisión y generalización:
- 3.1 **Evaluación del rendimiento del modelo:** Se evalúa el rendimiento del modelo utilizando métricas relevantes, como precisión, recall, F1-score, o la curva ROC, dependiendo del tipo de problema y del modelo.
- 3.2 **Validación cruzada:** Se realiza la validación cruzada para evaluar la capacidad de generalización del modelo en diferentes conjuntos de datos, lo que ayuda a identificar si el modelo está sobreajustado o subajustado.
- 3.3 **Ajuste de hiperparámetros:** Se pueden realizar ajustes adicionales en los hiperparámetros del modelo según los resultados de la validación para mejorar su rendimiento.
- 3.4 **Pruebas de robustez:** Se realizan pruebas adicionales para verificar la robustez del modelo frente a datos nuevos o inesperados, como datos ruidosos o outliers.
- 3.5 **Documentación del proceso:** Se documenta todo el proceso de validación, incluyendo los resultados obtenidos, las decisiones tomadas y cualquier otro detalle relevante.
- 4 **EMPAQUETADO DEL MODELO:** Empaqueta el modelo entrenado junto con cualquier archivo o biblioteca necesario en un formato compatible con el entorno de producción:
- 4.1 **Transformación de datos:** Los datos de entrada se transforman según las necesidades del modelo y los requisitos del entorno de producción.
- 4.2 **Empaquetado del modelo:** El modelo se empaqueta en un formato compatible con el entorno de implementación, como contenedores Docker o modelos ONNX.
- 4.3 **Optimización del modelo:** Se aplican técnicas de optimización para reducir el tamaño del modelo y mejorar su eficiencia computacional sin comprometer el rendimiento.
- 4.4 **Pruebas de integración:** Se realizan pruebas exhaustivas para garantizar que el modelo empaquetado funcione correctamente dentro del sistema de producción y se integre sin problemas con otras partes del sistema.
- 4.5 **Documentación y versionado:** Se documenta el proceso de empaquetado y se versiona el modelo empaquetado para facilitar su seguimiento y mantenimiento en el futuro.
- 5 **DESPLIEGUE EN UN ENTORNO DE PRODUCCIÓN:** Implementa el modelo empaquetado en un entorno de producción, como un servidor web, una aplicación móvil o un dispositivo IoT:
- 5.1 **Configuración del entorno:** Se prepara el entorno de producción, incluyendo servidores, bases de datos y otros recursos necesarios para ejecutar el modelo de forma eficiente.
- 5.2 **Despliegue del modelo:** El modelo empaquetado se implementa en el entorno de producción, asegurando que esté disponible para su uso y pueda manejar la carga de trabajo esperada.

- 5.3 **Monitorización y mantenimiento:** Se establecen sistemas de monitorización para supervisar el rendimiento del modelo en producción y realizar ajustes según sea necesario para garantizar su eficacia continua.
  - 5.4 **Actualizaciones y versionado:** Se implementan procesos para gestionar actualizaciones del modelo y su versión correspondiente en el entorno de producción, asegurando que siempre se utilice la versión más reciente y mejorada.
  - 5.5 **Escalado:** Se planifica el escalado del modelo según la demanda, asegurando que pueda manejar un aumento en la carga de trabajo sin comprometer su rendimiento.
- 6 **PRUEBA DE UN MODELO DESPLEGADO:** Realiza pruebas exhaustivas para garantizar que el modelo desplegado funcione correctamente y produzca resultados precisos en un entorno de producción:
- 6.1 **Pruebas de rendimiento:** Se realizan pruebas para evaluar la capacidad del modelo de manejar cargas de trabajo esperadas y su velocidad de respuesta bajo diferentes condiciones.
  - 6.2 **Pruebas de precisión:** Se verifica la precisión del modelo al realizar predicciones en datos reales del entorno de producción, comparando las predicciones con los resultados reales.
  - 6.3 **Pruebas de estabilidad:** Se evalúa la estabilidad del modelo durante períodos prolongados de operación para detectar posibles problemas de degradación del rendimiento con el tiempo.
  - 6.4 **Pruebas de seguridad:** Se realizan pruebas para garantizar que el modelo desplegado no presente vulnerabilidades de seguridad y cumpla con los estándares de protección de datos y privacidad.
  - 6.5 **Pruebas de escalabilidad:** Se evalúa la capacidad del modelo para escalar y manejar aumentos repentinos en la carga de trabajo sin comprometer su rendimiento.
- 7 **MONITOREO Y MANTENIMIENTO:** Establece un sistema de monitoreo para supervisar el rendimiento del modelo en producción y realiza ajustes o actualizaciones según sea necesario para mantener su precisión y eficacia a lo largo del tiempo:
- 7.1 **Monitoreo continuo:** Se implementan herramientas de monitoreo para rastrear métricas clave, como la precisión del modelo, el tiempo de respuesta y el rendimiento, con el fin de identificar posibles problemas o degradaciones en el rendimiento.
  - 7.2 **Optimización del modelo:** Se realizan ajustes en el modelo basados en los datos de monitoreo recopilados, lo que puede incluir la actualización de algoritmos, la adición de nuevas características o el reentrenamiento del modelo con datos más recientes.
  - 7.3 **Gestión de versiones:** Se lleva un registro de las diferentes versiones del modelo desplegado, lo que facilita la comparación de rendimiento entre versiones y la reversión a versiones anteriores si es necesario.
  - 7.4 **Resolución de problemas en tiempo real:** Se establecen alertas y procesos de respuesta rápida para abordar cualquier problema que surja con el modelo desplegado, minimizando el tiempo de inactividad y los impactos negativos en los usuarios finales.

**7.5 Actualizaciones de seguridad:** Se aplican parches de seguridad y se implementan medidas para proteger el modelo desplegado contra posibles vulnerabilidades y ataques cibernéticos.

- 8 **DOCUMENTACIÓN Y COMUNICACIÓN:** Documenta todo el proceso de despliegue, incluidos los datos utilizados, el modelo entrenado, los resultados de validación y cualquier configuración específica del entorno de producción. Comunica claramente los resultados y las implicaciones del modelo a todas las partes interesadas:
- 8.1 **Elaboración de documentación:** Se documentan todos los aspectos relevantes del proyecto, incluyendo el diseño del modelo, los datos utilizados, los procesos de entrenamiento y evaluación, y las decisiones clave tomadas durante el desarrollo.
  - 8.2 **Creación de manuales de usuario:** Se desarrollan manuales detallados para los usuarios finales, explicando cómo interactuar con el sistema y aprovechar al máximo sus funcionalidades.
  - 8.3 **Informes de resultados:** Se preparan informes que resumen los resultados obtenidos durante el desarrollo del modelo, incluyendo métricas de rendimiento, insights clave y recomendaciones para futuras mejoras.
  - 8.4 **Comunicación interna y externa:** Se establecen canales de comunicación efectivos tanto dentro del equipo de desarrollo como con partes interesadas externas, garantizando una colaboración fluida y una alineación en los objetivos del proyecto.
  - 8.5 **Gestión del conocimiento:** Se implementan herramientas y procesos para gestionar y compartir el conocimiento adquirido durante el desarrollo del modelo, facilitando su reutilización en proyectos futuros.

## 9 CASOS DE USO:

- 9.1 En un **proyecto de detección de fraudes en transacciones financieras**, se utiliza la validación cruzada para evaluar la capacidad del modelo para identificar transacciones fraudulentas en diferentes conjuntos de datos.
- 9.2 Para un **modelo de diagnóstico médico basado en imágenes**, se realizan pruebas de robustez para asegurar que el modelo pueda detectar correctamente enfermedades en diferentes condiciones de iluminación o calidad de imagen
- 9.3 En un **proyecto de análisis de datos para optimizar la cadena de suministro**, se preparan informes periódicos que resumen los hallazgos del análisis y proporcionan recomendaciones para mejorar la eficiencia operativa.
- 9.4 En un **sistema de recomendación de contenido en streaming**, se monitorean constantemente las interacciones de los usuarios con el sistema para ajustar los algoritmos de recomendación y mejorar la satisfacción del usuario.
- 9.5 En un **sistema de mantenimiento predictivo en la industria manufacturera**, se supervisan continuamente los datos de sensores para predecir fallos de equipos y programar mantenimiento preventivo.
- 9.6 En un **sistema de recomendación de productos en un sitio de comercio electrónico**, se prueban diferentes escenarios de carga de trabajo para verificar la capacidad del modelo para ofrecer recomendaciones personalizadas a un gran número de usuarios simultáneos.
- 9.7 En una **aplicación de detección de anomalías en el tráfico de red**, el modelo desplegado analiza continuamente los datos de tráfico para identificar posibles amenazas de seguridad.
- 9.8 En un **sistema de recomendación de productos en línea**, el modelo empaquetado se implementa para ofrecer recomendaciones personalizadas a los usuarios según su historial de compras y preferencias.
- 9.9 En un **proyecto de clasificación de imágenes médicas**, se entrena un modelo de red neuronal convolucional utilizando datos de imágenes etiquetadas para detectar enfermedades específicas.
- 9.10 En la **predicción de precios de acciones**, se utilizan datos históricos de precios y volúmenes para entrenar un modelo de regresión que predice los precios futuros de las acciones.
- 9.11 Para el **reconocimiento de voz**, se entrena un modelo de aprendizaje profundo con grabaciones de voz y transcripciones correspondientes para convertir señales de audio en texto escrito con precisión.
- 9.12 En un **proyecto de clasificación de spam de correo electrónico**, la fase de preprocesamiento de datos implica la eliminación de correos electrónicos duplicados, la normalización de la longitud de los mensajes, la codificación de las palabras clave como características binarias y la selección de características relevantes, como la frecuencia de palabras clave específicas. Esto garantiza que el modelo pueda aprender patrones efectivamente y distinguir entre correos electrónicos legítimos y spam con precisión.

#####

## # 15 (Implemente el modelo en una aplicación web o API)

# ¿Cómo se implementa un modelo de machine learning en una aplicación web o API?

# (Esta parte depende de la plataforma de deployment que se elija)

La implementación del modelo en el caso concreto de una web o API consta de fases parecidas al deployment, y resaltamos las exclusivas a la web o API:

- 1 **Entrenamiento del modelo:** Primero, se entrena el modelo utilizando datos relevantes y técnicas de machine learning adecuadas para el problema que se está abordando.
- 
- 2 **DESARROLLO DE LA APLICACIÓN/API:** Se construye la aplicación web o se configura la API que actuará como interfaz para el modelo de machine learning.
- 3 **INTEGRACIÓN DEL MODELO EN LA APLICACIÓN/API:** Se incorpora el modelo de machine learning en la lógica de la aplicación web o en la API, lo que implica escribir código para consumir el modelo y realizar predicciones basadas en los datos de entrada proporcionados.
- 4 **DESPLIEGUE EN UN ENTORNO WEB:** El código de la aplicación web o de la API, junto con el modelo de machine learning integrado, se despliega en un servidor web accesible a través de internet para que los usuarios puedan interactuar con él.
- 5 **IMPLEMENTACIÓN DE INTERFACES DE USUARIO (UI):** Se desarrollan interfaces de usuario intuitivas y amigables que permitan a los usuarios interactuar con la aplicación web y proporcionar los datos de entrada necesarios para realizar predicciones utilizando el modelo de machine learning.
- 6 **PRUEBAS Y OPTIMIZACIÓN:** Se realizan pruebas exhaustivas para garantizar que la aplicación web o la API funcionen correctamente y se optimizan para mejorar el rendimiento y la experiencia del usuario.
- 7 **GESTIÓN DE ERRORES Y MONITOREO:** Se establecen mecanismos para gestionar errores de manera efectiva y se implementan sistemas de monitoreo para supervisar el funcionamiento de la aplicación web o la API, así como el rendimiento del modelo de machine learning integrado.
- 8 **ACTUALIZACIONES Y MANTENIMIENTO:** Se planifican y llevan a cabo actualizaciones periódicas para mantener la aplicación web o la API y el modelo de machine learning al día con los cambios en los datos y las necesidades del negocio.
- 
- 9 **Preprocesamiento de datos:** Si es necesario, se realiza el preprocesamiento de los datos de entrada en la aplicación/API para que sean compatibles con el formato esperado por el modelo.
- 10 **Consumo del modelo:** La aplicación web o API está configurada para consumir el modelo, enviando datos de entrada al modelo y recibiendo las predicciones o resultados correspondientes.
- 11 **Gestión de errores y rendimiento:** Se implementan mecanismos para gestionar errores y supervisar el rendimiento del modelo en producción, como registros detallados y alertas automáticas.
- 12 **Casos de uso:**
  - 12.1 **Análisis de sentimientos en redes sociales:** Se desarrolla un modelo de análisis de sentimientos para clasificar los comentarios de las redes sociales como positivos, negativos o neutros, y se integra en una aplicación web que permite a los usuarios analizar el sentimiento de sus publicaciones o de un conjunto de datos específico.



## #16 Conclusiones

# (Explique los resultados del proyecto y su impacto en el problema de negocio)

# Investigar cómo presentar resultados de proyecto de Ciencia de datos que impacte al público

Algunas de los puntos estratégicos que pueden marcar el impacto en el público son:

- 1 **CONOCER A TU AUDIENCIA:** Comprende quiénes son tus espectadores y adapta tu presentación para que sea relevante y comprensible para ellos:
  - 1.1 **Identifica a los interesados principales:** Determina quiénes son las personas o grupos que estarán involucrados en la toma de decisiones basadas en los resultados de tu proyecto.
  - 1.2 **Comprende sus necesidades y prioridades:** Investiga cuáles son los desafíos, metas y preocupaciones principales de tu audiencia en relación con el tema de tu proyecto de Ciencia de Datos.
  - 1.3 **Evalúa su nivel de conocimiento técnico:** Determina el grado de familiaridad que tienen tus espectadores con los conceptos y técnicas de Ciencia de Datos para adaptar tu presentación en consecuencia.
  - 1.4 **Identifica los requisitos de presentación de información:** Averigua qué formatos de datos, visualizaciones o análisis son más útiles y comprensibles para tu audiencia.
  - 1.5 **Considera el contexto y el entorno de uso:** Piensa en cómo se utilizarán los resultados de tu proyecto en el contexto específico de tu audiencia y adapta tu enfoque en consecuencia.
- 2 **DEFINIR EL PROBLEMA Y EL OBJETIVO:** Explica claramente cuál era el problema que intentabas resolver y cuál era tu objetivo al realizar el proyecto de Ciencia de Datos:
  - 2.1 **Identificación del problema:** Comprender y definir claramente el problema que se abordará con el proyecto de Ciencia de Datos. Esto implica determinar los desafíos o las áreas de mejora que la organización enfrenta y que podrían beneficiarse del análisis de datos.
  - 2.2 **Establecimiento de objetivos SMART:** Definir objetivos específicos, medibles, alcanzables, relevantes y con un marco temporal (SMART, por sus siglas en inglés). Estos objetivos deben ser claros y proporcionar una guía clara sobre lo que se espera lograr con el proyecto.
  - 2.3 **Comprensión del contexto empresarial:** Considerar el contexto empresarial más amplio en el que se enmarca el problema y los objetivos del proyecto. Esto implica comprender la visión, misión y estrategia de la organización, así como las necesidades específicas de los stakeholders.
  - 2.4 **Identificación de métricas de éxito:** Determinar cómo se medirá el éxito del proyecto, qué métricas se utilizarán para evaluar el rendimiento y el impacto de las soluciones propuestas.
  - 2.5 **Validación con stakeholders:** Obtener retroalimentación y validación de los stakeholders relevantes para asegurarse de que el problema y los objetivos definidos reflejen con precisión las necesidades y prioridades de la organización.

- 3 **DESTACAR LAS PRINCIPALES CONCLUSIONES Y RECOMENDACIONES:** Resalta las conclusiones más importantes de tu proyecto y sugiere recomendaciones claras y accionables basadas en tus hallazgos:
  - 3.1 **Resumen de conclusiones:** Presentar de manera clara y concisa las conclusiones más importantes derivadas del análisis de datos. Esto incluye los patrones, tendencias o insights identificados durante el proyecto.
  - 3.2 **Visualización de datos:** Utilizar gráficos, tablas u otros recursos visuales para destacar las conclusiones de manera efectiva y comprensible. Las visualizaciones ayudan a transmitir la información de manera más impactante y fácil de entender.
  - 3.3 **Relevancia empresarial:** Enfatizar la relevancia de las conclusiones para los objetivos del negocio o las necesidades de los stakeholders. Es importante mostrar cómo las conclusiones pueden influir en la toma de decisiones y generar valor para la organización.
  - 3.4 **Recomendaciones accionables:** Proveer recomendaciones claras y específicas basadas en las conclusiones obtenidas. Estas recomendaciones deben ser prácticas y orientadas a la acción, con el objetivo de impulsar mejoras o cambios positivos en la organización.
  - 3.5 **Comunicación efectiva:** Presentar las conclusiones y recomendaciones de manera clara y persuasiva, adaptándose al público objetivo. Es fundamental asegurarse de que la información sea comprensible y relevante para los stakeholders involucrados.
- 4 **MOSTRAR EL IMPACTO:** Utiliza visualizaciones de datos efectivas y ejemplos concretos para ilustrar el impacto de tus resultados en la vida real:
  - 4.1 **Medición de resultados:** Cuantificar y cualificar los resultados obtenidos a partir del proyecto de Ciencia de Datos. Esto implica evaluar cómo las acciones derivadas del análisis de datos han contribuido al logro de los objetivos establecidos.
  - 4.2 **Comparación con objetivos iniciales:** Contrastar los resultados obtenidos con los objetivos iniciales del proyecto. Es importante verificar si se han cumplido, superado o incluso modificado estos objetivos en función de los hallazgos y el impacto observado.
  - 4.3 **Ejemplos concretos:** Utilizar ejemplos concretos y casos de uso para ilustrar el impacto del proyecto en situaciones reales. Estos ejemplos pueden ayudar a visualizar cómo se aplican los insights obtenidos y cómo afectan a las operaciones o decisiones de la organización.
  - 4.4 **Comunicación efectiva:** Comunicar los resultados de manera clara y persuasiva, adaptándose al público objetivo. Es crucial destacar el valor agregado que el proyecto de Ciencia de Datos ha proporcionado y cómo ha contribuido al éxito organizacional.
  - 4.5 **Feedback y aprendizaje:** Recoger feedback tanto interno como externo sobre el impacto del proyecto. Esto puede ayudar a identificar áreas de mejora y a aprender de la experiencia para futuros proyectos de Ciencia de Datos.
- 5 **SER CLARO Y CONCISO:** Evita jerga técnica excesiva y utiliza un lenguaje simple y directo para comunicar tus ideas de manera efectiva:
  - 5.1 **Definición de objetivos:** Establecer objetivos claros y medibles desde el principio del proyecto para mantener el enfoque y la claridad en todas las etapas.
  - 5.2 **Presentación de resultados:** Comunicar los hallazgos de manera clara y sin ambigüedades, utilizando visualizaciones efectivas y lenguaje accesible para el público objetivo.

- 5.3 **Eliminación de información redundante:** Evitar la inclusión de datos o información irrelevante que pueda dificultar la comprensión de los resultados.
  - 5.4 **Estructura organizada:** Organizar la presentación de los resultados de manera lógica y coherente, siguiendo una estructura que facilite la comprensión y la navegación.
  - 5.5 **Uso de ejemplos concretos:** Ilustrar conceptos abstractos con ejemplos concretos y casos de uso relevantes para proporcionar contexto y claridad.
  - 5.6 **Resumen ejecutivo:** Incluir un resumen ejecutivo que destaque los puntos clave y las conclusiones principales de manera sucinta y directa.
  - 5.7 **Revisión por pares:** Solicitar la revisión por parte de colegas o expertos en el tema para garantizar que la presentación sea clara y comprensible para la audiencia prevista.
- 6 **UTILIZAR UNA NARRATIVA CONVINCENTE:** Cuenta una historia coherente que guíe a tu audiencia a través de los datos y los resultados, manteniendo su interés en todo momento:
- 6.1 **Definir una estructura narrativa:** Establecer un principio, desarrollo y desenlace claro para la presentación de los datos, creando así una narrativa coherente y fácil de seguir.
  - 6.2 **Identificar el público objetivo:** Conocer a la audiencia permite adaptar la narrativa y el lenguaje para que sean relevantes y comprensibles para quienes recibirán la información.
  - 6.3 **Utilizar ejemplos y casos reales:** Incorporar ejemplos concretos y escenarios de la vida real ayuda a ilustrar los puntos clave y a hacer la narrativa más atractiva y relevante.
  - 6.4 **Visualizaciones efectivas:** Apoyar la narrativa con visualizaciones de datos claras y impactantes que refuercen los argumentos y faciliten la comprensión de la información.
  - 6.5 **Crear una conexión emocional:** Incorporar elementos que generen empatía o despierten interés emocional en la audiencia puede hacer que la narrativa sea más convincente y memorable.
  - 6.6 **Destacar conclusiones y recomendaciones:** Resaltar las principales conclusiones y recomendaciones del análisis de datos dentro de la narrativa para guiar a la audiencia hacia la acción o la toma de decisiones.

**FIN**